

Relatório de Leitura

Lucas Buligon Antunes

Data de finalização: 05/09/2023

Artigo base:

ALVES, João Miguel Ribeiro. **Deteção de incêndios florestais com recurso a Deep Learning e Visão Computacional.** masterThesis, 2018. Disponível em: <<https://bdigital.ufp.pt/handle/10284/7058>>. Acesso em: 5 set. 2023.

1.Introdução

O trabalho apresenta um sistema de detecção automática de incêndios que procura minimizar este problema ao permitir sua detecção em seus estágios iniciais. Pensado para ser um sistema de baixo custo para variadas condições (dia/noite, ausência/presença de chama e intervenção humana, diferentes estações do ano, entre outros), atingiu uma precisão de 94,1% em cenários diurnos e de 94,8% em cenários noturnos, demonstrando boa precisão na estimativa. Tendo o diferencial de ser planejado para atuar tanto em estações móveis (drones) como fixas.

Além disso, parte importante do trabalho é a análise de dados meteorológicos realizada pelo sistema, de modo a poupar recursos e não levantar voo (no caso de drones) caso não seja necessário. Na figura 01 é possível ver a arquitetura completa do sistema, já na figura 02 é possível observar a tomada de decisão realizada.

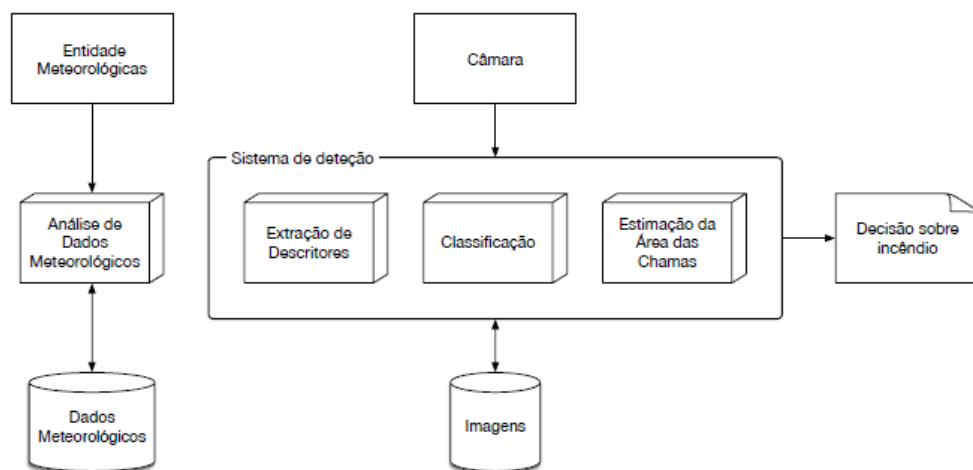


Figura 01 - Vista completa da arquitetura do sistema

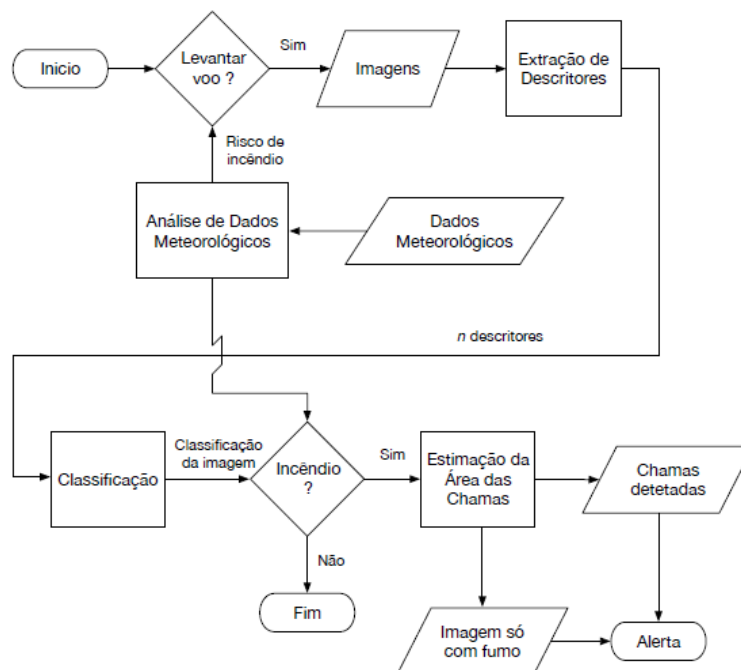


Figura 02 - Diagrama de fluxo do sistema

Para a identificação das imagens o sistema faz uso de uma DCNN (*Deep Convolutional Neural Network*), para a extração de descritores, aliada a um classificador de ML. O modelo de DCNN escolhido foi o Inception-V3, o qual já possui um classificador integrado em sua última camada, porém esse não é treinado para o conjunto de imagens utilizado no trabalho. Dessa forma, recorreu-se à técnica de *Transfer Learning*, sendo utilizada apenas a parte de extração de descritores (que é a parte mais complexa) com um classificador treinado especificamente para o caso. A escolha da DCNN Inception-V3 baseou-se no fato de ser uma das melhores em termos de precisão quando comparada com outras.

Entre as funcionalidades do sistema também está estimar a área das chamas presentes na imagem, caso elas sejam detectadas. Esse módulo utiliza a arquitetura observada na figura 03, baseando-se na regra *Piecewise-Linear Transformation* (PLT): as regiões da imagem que não apresentarem cores entre o laranja e o vermelho, passarão a verde. Deste modo, potencia-se a separação entre o grupo de pixels relativos à chama dos restantes. Já o componente FFDI envolve a normalização do espaço de cor RGB, o cálculo do índice FFDI e a determinação do valor de threshold para aplicar a segmentação.

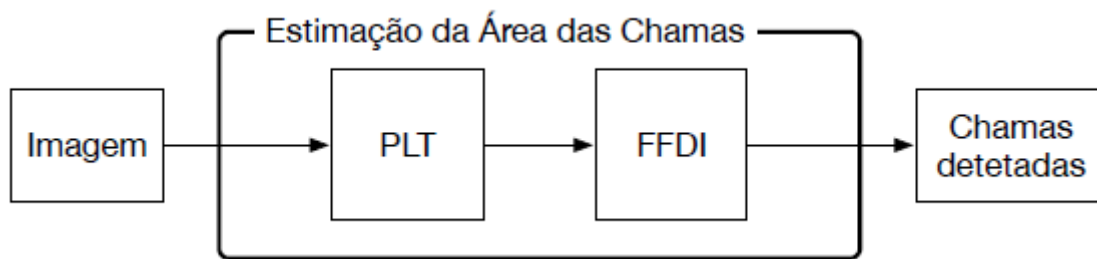


Figura 03 - Detalhe da arquitetura do módulo de estimativa da área das chamas

Após finalizado, o sistema passou por diversos testes, demonstrando ótimos resultados. Sendo a presença de nevoeiros durante o dia e de luzes de iluminação à noite as características com maior responsabilidade pela ocorrência de falsos positivos por parte do modelo classificação. Outra limitação encontrada para o modelo foi a pouca disponibilidade de imagens com perspectiva aérea, o que não levou à obtenção de melhores e mais conclusivos resultados.

2. Discussões realizadas

Vale ressaltar o intenso trabalho de pesquisa e testes realizado durante o trabalho. Desde a seção sobre o estado da arte há grande discussão sobre qual modelo deve ser utilizado para o caso e o porquê das escolhas terem sido feitas de tal maneira, como é possível observar na figura 04. De modo que é um ótimo exemplo de passo-a-passo para a criação de outros modelos na área. Além disso, condições geográficas e de obtenção de imagem também são amplamente discutidas.

Sistema	DCNN	Chama	Fumo	Noite	Precisão	Dataset
(Huttner et al., 2017)	Inception-V3	✓	✓	✗	99.7%	++
(Sharma et al., 2017)	Resnet50 modificada	✓	✓	✓	92.15%	++
(Sharma et al., 2017)	VGG16 modificada	✓	✓	✓	91.18%	++
(Wonjae Lee et al., 2017)	GoogLeNet	✓	✓	n/a	99%	++
(Wonjae Lee et al., 2017)	AlexNet	✓	✓	n/a	94.8%	++
(Wonjae Lee et al., 2017)	VGG13 modificada	✓	✓	n/a	96.2%	++
(Zhang et al., 2016)	AlexNet NN-Pool5	✓	✗	✗	97.3%	+
(Kim et al., 2016)	CNN simples	✓	✓	✓	88.54%	++

Figura 04 - Comparação entre sistemas de detecção de incêndios baseados em DCNN

Juntamente a isso, ao terminar o modelo, ele é amplamente testado com os metadados utilizados durante todo o processo, fazendo o uso de matrizes de confusão para validar os resultados obtidos. É possível observar um exemplo na figura 05, a qual apresenta o teste mediante zonas de campo.

		Predicted		
		Incêndio	Sem Incêndio	Σ
Actual	Incêndio	19	1	20
	Sem Incêndio	1	43	44
Σ		20	44	64

Figura 05 - Matriz de confusão do teste realizado perante situações sem floresta

3. Conclusão

O trabalho serve de ótima referência para a criação de sistemas que utilizam da visão computacional para a resolução de problemas. Sendo um exemplo da construção de modelos de identificação de imagens e trazendo diversas referências externas sobre o assunto, de modo que fornece um vasto acervo para pesquisa.